

Motion Planning as Probabilistic Inference using Gaussian Processes and Factor Graphs

Mikołaj Michałek Tomasz Lesiński

Sztuczna Inteligencja w Robotyce
Prowadząca: mgr inż. Joanna Piasek-Skupna

Politechnika Poznańska
Wydział Automatyki, Robotyki i Elektrotechniki

26 maja 2026



Plan

- 1 Planowanie ruchu jako optymalizacja trajektorii
- 2 Reprezentacja trajektorii jako graf czynników
- 3 Trajektorja ciągła w czasie, dyskretna optymalizacja
- 4 Biblioteka GPMP2
- 5 Obiekt analizowany w artykule
- 6 Co adaptujemy z artykułu?
- 7 Nasz obiekt i problem planowania
- 8 Graf Czynników
- 9 Wyniki symulacji
- 10 Zalety i wady

Główna idea artykułu


Planowanie ruchu można potraktować jako problem znalezienia najbardziej prawdopodobnej trajektorii, która jest jednocześnie gładka, prowadzi od startu do celu oraz unika przeszkód.

$$\theta^* = \arg \min_{\theta} \left\{ \frac{1}{2} \|\theta - \mu\|_K^2 + \frac{1}{2} \|h(\theta)\|_{\Sigma_{\text{obs}}}^2 \right\} \quad (1)$$

- θ – optymalizowana trajektoria robota,
- μ – trajektoria referencyjna wynikająca z modelu ruchu,
- $\|\theta - \mu\|_K^2$ – koszt gładkości trajektorii,
- $h(\theta)$ – koszt związany z przeszkodami,
- Σ_{obs} – waga kosztu przeszkód.

Reprezentacja trajektorii jako graf czynników


Trajektoria robota jest zapisana jako zbiór kolejnych stanów połączonych zależnościami. Każda zależność dodaje określony koszt, np. za oddalenie od startu lub celu, brak płynności ruchu albo zbliżenie do przeszkody. Optymalizacja polega na takim przesunięciu punktów trajektorii, aby suma tych kosztów była jak najmniejsza.



Trajektoria ciągła w czasie, dyskretna optymalizacja

Główna idea

Trajektoria robota jest traktowana jako funkcja ciągła czasu, ale algorytm optymalizuje tylko wybrane stany. Punkty pomiędzy nimi są wyznaczane przez interpolację procesu Gaussa, dzięki czemu można sprawdzać kolizje bez zwiększania liczby zmiennych optymalizacyjnych. W efekcie uzyskujemy trajektorię, która jest opisana małą liczbą stanów, ale może być gęsto sprawdzana pod kątem kolizji.



Planowanie ruchu jako wnioskowanie


GPMP2 traktuje trajektorię robota jako ciąg stanów połączonych w grafie czynników. Zamiast szukać ścieżki losowo, algorytm optymalizuje całą trajektorię tak, aby spełniała zadane kryteria. GPMP2 łączy gładkość ruchu, unikanie przeszkód oraz warunki startu i celu w jednym problemie optymalizacji.

Informacje:

- trajektoria jest opisana jako proces Gaussa,
- graf czynników zapisuje zależności między kolejnymi stanami,
- czynniki przeszkód zwiększają koszt w pobliżu kolizji,
- czynniki GP wymuszają płynność ruchu,
- wynik optymalizacji to trajektoria o najmniejszym łącznym koszcie.

Obiekt analizowany w artykule

Autorzy testowali metodę na robotach manipulacyjnych o 7 stopniach swobody, głównie na ramieniu WAM oraz robocie PR2. Planowanie dotyczyło ruchu ramienia od konfiguracji startowej do docelowej z uwzględnieniem przeszkód w otoczeniu.



Co adaptujemy z artykułu?


Główna idea

Z artykułu przenosimy podejście, w którym planowanie ruchu jest traktowane jako problem optymalizacji trajektorii. Trajektoria nie jest wyznaczana ręcznie, tylko dopasowywana do zestawu kosztów.

Założenia:


- graf czynników jako reprezentacja problemu optymalizacji trajektorii,
- koszt przeszkód jako składnik kary za punkty zbyt blisko obszarów niebezpiecznych,
- koszt gładkości zapisany jako GP Prior, czyli kara za odchylenie od modelu ruchu ze stałą prędkością,
- warunki startu i celu,
- biblioteka GTSAM do budowy grafu czynników i wyznaczenia trajektorii.

Nasz obiekt i problem planowania




Nasz obiekt i problem planowania


Pseudo-GPMP: omijanie kulistych przeszkód w przestrzeni 3D




Graf Czynników





Wyniki symulacji



Wyniki symulacji







Dziękujemy za uwagę